

VISIÓ PER COMPUTADOR

Sistema de Detecció i Classificació de Senyals de Trànsit

Autors: Enric Segarra, Alexander de Jong

21 de juny de 2026

Índex

1	Introducció i objectius	2
1.1	Dataset i distribució de classes	2
2	Segmentació	2
2.1	Transformació de l'espai de color	3
2.2	Llindars de Color	3
2.3	Processament Morfològic	3
2.4	Filtratge geomètric i selecció de candidats	4
2.5	Validació Qualitativa: Estudi de Casos	4
2.5.1	Cas 1: Robustesa davant el Cel Blau (El conflicte Cian)	5
2.5.2	Cas 2: Senyals de Límit de Velocitat vs. Cel Clar	6
2.5.3	Cas 3: Gestió de Fons Complexos i Textures	7
2.5.4	Cas 4: Senyals de Prohibició Estàndard	7
3	Descriptors i característiques utilitzades	7
3.1	Enumeració i descripció de les característiques utilitzades	7
3.2	Característiques geomètriques (forma)	8
3.3	Característiques de color	8
3.4	Histograma de gradients orientats (HOG)	8
4	Preparació de l'Experimentació	9
4.1	Normalització de Dades	9
4.2	Persistència dels Paràmetres per a Inferència	9
4.3	Metodologia global del sistema (pipeline complet)	10
5	Experimentació i Resultats	11
5.1	Experiment 1: Importància dels Descriptors (Ablation Study)	11
5.1.1	Configuració de l'Experiment	11
5.1.2	Resultats i Discussió	11
5.2	Experiment 2: Selecció del Classificador	11
5.2.1	Resultats quantitatius (k-fold = 5)	12
5.2.2	Com funciona cada model i interpretació dels resultats	12
5.2.3	Anàlisi focalitzat en classes crítiques	13
5.2.4	Conclusions de l'Experiment 2	14
5.3	Model definitiu (proposta)	14
5.4	Experiment 3: Validació Qualitativa amb Imatges Externes	15
5.4.1	Conclusions de l'Experiment 3	17
6	Conclusions i treball futur	17
6.1	Principals aportacions i decisions clau	18
6.2	Què hem après dels errors (limitacions)	18
6.3	Línies de millora (treball futur)	18
6.4	Conclusió final	19

1 Introducció i objectius

En el camp de la visió per computador, el reconeixement d'objectes dintre d'imatges sempre ha sigut un dels principals objectius, disposant avui en dia de diferents tècniques i metodologies per a aconseguir-ho. Tot i això, continua havent-hi marge de millora, sent un àmbit amb un grandíssim interès darrere, creant molta recerca i investigació per incrementar la fiabilitat que s'ha aconseguit actualment.

L'objectiu d'aquest treball és una part concreta d'aquest camp: el reconeixement de senyals de trànsit. Tot i ser molt més específic, identificar aquests senyals és d'una gran importància per a moltes aplicacions actuals, com ara l'assistència al conductor dels cotxes actuals (sistema ADAS) o la futurística conducció autònoma, la qual conforma un dels grans objectius de moltes empreses automobilístiques, essent cada dia que passa més viable.

A partir dels mètodes estudiats al llarg del curs, s'ha intentat realitzar el millor reconeixement possible, identificant si hi ha senyal de trànsit o no i, en cas afirmatiu, classificar-la en una de les deu possibles classes de senyals que estipula l'enunciat. A continuació, en aquest informe es documenta la metodologia emprada per assolir aquests objectius i el raonament darrere d'aquesta, junt amb l'experimentació realitzada i els resultats obtinguts.

1.1 Dataset i distribució de classes

El conjunt de dades utilitzat conté un total de 2775 imatges distribuïdes en 11 carpetes (classes): `d_obligatoria`, `d_prohibida`, `limit`, `no_aparcar`, `no_girar`, `no_senyal`, `no_soroll`, `stop`, `vianant`, `zona_bici` i `zona_cotxe`.

Cal remarcar que el dataset original proporcionat **no incloïa la classe `no_senyal`** (imatges sense cap senyal). Aquesta classe l'hem afegida nosaltres per poder entrenar el sistema a distingir entre "hi ha senyal" i "no hi ha senyal". En una primera iteració, es van incorporar aproximadament 70 imatges a `no_senyal` i, posteriorment, se n'han afegit moltes més per reforçar la classe (aproximadament 360); aquesta ampliació ha millorat de manera clara el *recall* de `no_senyal` en l'avaluació interna.

És important remarcar que el dataset és desbalancejat (per exemple, `limit` té moltes més mostres que `stop` o `no_senyal`). Per aquest motiu, durant l'experimentació no només s'avalua la precisió global (*accuracy*), sinó també el comportament per classe mitjançant la matriu de confusió i el *recall* per classe.

2 Segmentació

El procés de segmentació és la primera etapa crítica del sistema i té com a objectiu aïllar les Regions d'Interès (ROI), que potencialment contenen un senyal de trànsit, eliminant la resta de l'escena (cel, carretera, vegetació).

S'ha implementat un algorisme basat en la detecció de color en l'espai HSV, reforçat amb operacions morfològiques i filtratge geomètric. A continuació es detallen les fases de l'algorisme:

2.1 Transformació de l'espai de color

La imatge original en format RGB (Vermell, Verd, Blau) es converteix a l'espai de color HSV (Matís, Saturació, Valor). Aquesta transformació és fonamental perquè l'espai RGB és molt sensible a les variacions d'il·luminació (ombres, sol directe), mentre que l'HSV separa la informació cromàtica (H) de la intensitat lumínica (V), permetent una detecció més robusta en exteriors.

2.2 Llindars de Color

S'han definit màscares binàries per als tres colors principals dels senyals: vermell, blau i groc. Els rangs s'han ajustat experimentalment per maximitzar la detecció del senyal i minimitzar el soroll ambiental:

- **Màscara Vermella:** Es gestiona la particularitat cíclica del canal H (el vermell es troba als extrems 0 i 1). S'accepten píxels amb $H > 0.90$ o $H < 0.12$. S'estableix una saturació mínima ($S > 0.15$) i brillantor ($V > 0.15$) per evitar detectar objectes grisos foscos o negres.
- **Màscara Blava:** S'ha aplicat un filtratge estricte per evitar la confusió habitual amb el cel. El rang de matís s'ha fixat en $H \in [0.57, 0.77]$. El límit inferior de 0.57 és crític, ja que permet descartar els tons cian (blau cel) mantenint el blau característic dels senyals (sobretot la classe zona cotxe). La saturació mínima és més exigent ($S > 0.25$) per garantir colors vius.
- **Màscara Groga (Obres):** S'ha limitat el rang superior a $H < 0.19$ per evitar la detecció de fulles verdes groguenques o vegetació seca.

2.3 Processament Morfològic

Un cop obtinguda la màscara binària combinada (`bw_raw`), s'aplica una seqüència d'operacions morfològiques per millorar la qualitat de la regió detectada:

- Dilatació** (`imdilate`, `disc` $r = 3$): Connecta components propers que podrien haver quedat separats (per exemple, si el pictograma intern del senyal trenca la continuïtat del color).
- Ompliment de forats** (`imfill`): Converteix el senyal en un objecte sòlid, eliminant els buits interns generats pels símbols blancs o negres del senyal.
- Erosió** (`imerode`, `disc` $r = 3$): Restaura la mida original de l'objecte després de la dilatació, perfilant-ne les vores.
- Obertura** (`imopen`, `disc` $r = 2$): Elimina el soroll residual de mida petita (soroll de sal) i desconnecta elements fins com branques d'arbres que puguin haver quedat units al senyal.

2.4 Filtratge geomètric i selecció de candidats

Finalment, s'analitzen les regions connectades (*blobs*) resultants per decidir quines són senyals vàlids. S'apliquen tres criteris:

- **Filtre d'Àrea:** S'eliminen tots els objectes amb menys de 150 píxels, considerats soroll.
- **Relació d'Aspecte (Aspect Ratio):** Es calcula la proporció entre l'amplada i l'alçada de la caixa contenidora (*Bounding Box*). S'accepten objectes amb una relació entre 0.4 i 2.2, descartant així objectes molt allargats o aplanats (com línies de la carretera o pals).
- **Consistència (Extent):** Es calcula la relació entre l'àrea de l'objecte i l'àrea de la seva caixa contenidora. S'exigeix un valor > 0.25 per descartar objectes amb formes molt disperses o buides (típic de la vegetació).

Com a mesura de seguretat, l'algorisme inclou una lògica de rescat: si cap objecte supera els filtres geomètrics estrictes però hi ha detecció de color significativa, el sistema selecciona la regió de color més gran per evitar perdre un senyal que pugui estar parcialment oclòs o deformat.

2.5 Validació Qualitativa: Estudi de Casos

Per tal de verificar la robustesa de l'algorisme de segmentació proposat, s'han seleccionat cinc escenaris reals que presenten dificultats habituals en visió per computador (il·luminació variable, fons complexos i similitud cromàtica). A continuació s'analitza el comportament del sistema en cadascun d'ells.

2.5.1 Cas 1: Robustesa davant el Cel Blau (El conflicte Cian)




Figura 1: Segmentació d'un senyal STOP amb fons de cel blau intens.

A la Figura 1 s'observa un senyal d'STOP vermell retallat contra un cel blau clar. Aquest és un cas crític ja que molts algorismes confonen la lluminositat del cel amb el blanc del senyal, o el blau del cel amb senyals d'obligació.

- **Anàlisi:** La segmentació es basa en umbrals en l'espai HSV. Per evitar confondre cel i núvols amb el senyal, s'exigeix una saturació mínima (S) i una lluminositat mínima (V). En el cas del vermell s'accepta $V > 0.15$ i per al groc $V > 0.25$, reduint falsos positius en zones molt clares.
- **Resultat:** Segmentació correcta del senyal, i el filtratge geomètric (àrea, aspect ratio i extent) descarta regions no compatibles amb una senyal.

2.5.2 Cas 2: Senyals de Límit de Velocitat vs. Cel Clar



Figura 2: Senyal de prohibició (80 km/h) amb fons de cel i branques fines.

En aquest cas (Figura 2), l'anella vermella del senyal és prima i el fons és un cel blau molt lluminós.

- **Anàlisi:** Es detecta l'anella vermella amb umbrals de to (H) i saturació (S) en HSV, i després s'apliquen operacions morfològiques (dilatació, omplir forats, erosió i obertura) per connectar i netejar la regió.
- **Resultat:** La regió del senyal queda aïllada de manera raonable tot i ser prima, i el filtratge geomètric ajuda a descartar branques o fragments del cel.

2.5.3 Cas 3: Gestió de Fons Complexos i Textures



Figura 3: Senyal de carril bici amb fons de vegetació densa.

La Figura 3 presenta un senyal blau envoltat d'una trama complexa de branques. Aquest "soroll d'alta freqüència" sol trencar la continuïtat de la segmentació.

2.5.4 Cas 4: Senyals de Prohibició Estàndard



Figura 4: Senyal de prohibició acústica.

3 Descriptors i característiques utilitzades

3.1 Enumeració i descripció de les característiques utilitzades

Un cop segmentada la regió d'interès (ROI), el sistema extreu un conjunt de descriptors numèrics per caracteritzar el senyal. S'ha dissenyat un **vector de característiques híbrid** que integra informació **geomètrica**, **cromàtica** i de **textura**.

El procés s'inicia amb l'extracció de **1.771 valors bruts per imatge** (4 de forma + 3 de color + 1.764 de HOG), als quals s'aplica una **ponderació estratègica** i posteriorment una **reducció de dimensionalitat** (via PCA sobre la part HOG,

explicada més endavant), donant com a resultat un vector final d'entrenament molt més compacte, de **157 valors** (7 descriptors manuals + 150 components PCA).

3.2 Característiques geomètriques (forma)

Atesa la naturalesa estandarditzada dels senyals de trànsit, la forma és el discriminador més potent per distingir entre famílies (circulars, triangulars, quadrades). S'extreuen **4 descriptors** robustos i relativament invariants a canvis d'escala i a rotacions moderades. Al codi, s'aplica un pes de ponderació $w_{shape} = 6$ a aquestes variables per augmentar-ne la rellevància dins el classificador:

- **Compacitat** (Perímetre²/Àrea): relaciona el quadrat del perímetre amb l'àrea. Aquest valor és mínim per a cercles perfectes i augmenta progressivament per a formes amb més perímetre com triangles o quadrats.
- **Solidesa** (*solidity*): mesura la compacitat de l'objecte respecte a la seva envoltura convexa (*convex hull*). Permet diferenciar formes sòlides (senyals reals) de formes irregulars amb entrades o buits (branques o errors de segmentació).
- **Extent** (ocupació de la *bounding box*): relació entre l'àrea de l'objecte i l'àrea de la seva caixa contenidora. Ajuda a diferenciar formes que omplen gairebé tota la caixa (p. ex. rectangles, valors més propers a 1) d'altres com triangles o cercles, que deixen cantonades buides (valors típicament més baixos).
- **Excentricitat**: mesura l'allargament de la forma (0 per a un cercle perfecte, apropant-se a 1 per a el·lipses molt estretes).

3.3 Característiques de color

El color és un descriptor útil per diferenciar senyals amb **forma similar** (p. ex. circulars), però sol ser menys estable que la forma sota canvis d'il·luminació. Per capturar aquesta informació de manera més robustament, després de segmentar la ROI es transforma a canal HSV.

A diferència d'un histograma de color clàssic, el nostre sistema calcula **tres descriptors** basats en la **proporció de píxels** corresponents als colors característics dels senyals: **vermell**, **blau** i **groc**. Cada color es defineix mitjançant intervals del canal de tonalitat (H) i un llindar mínim de saturació (S), assegurant que només es comptabilitzen colors vius i representatius. Aquests percentatges es normalitzen respecte al nombre total de píxels vàlids (no negres) i es ponderen amb $w_{color} = 2$ dins del vector de característiques final.

3.4 Histograma de gradients orientats (HOG)

Finalment, quan la forma i el color no són suficients per classificar correctament el senyal, és necessari capturar el **contingut estructural intern** (pictogrames, dígit i vores). Per fer-ho, utilitzem el descriptor **HOG** (*Histogram of Oriented Gradients*).

Abans de l'extracció, la ROI segmentada es redimensiona a una mida fixa de 64×64 píxels per garantir coherència dimensional independentment de la mida original del senyal. El descriptor es calcula dividint la imatge en cel·les de 8×8 píxels, sobre les quals es construeixen histogrames d'orientació dels gradients d'intensitat.

El càlcul genera un vector d'alta dimensionalitat de mida **1.764**. Un cop calculat, es pondera amb un pes $w_{hog} = 0.3$, fent que la textura tingui una importància menor que la dels descriptors de forma i color.

Aquests pesos s'han ajustat per compensar la diferència de quantitat entre variables. Com que el vector HOG (i el posterior PCA) té moltes més dades (150 components) que els descriptors de forma (només 4), si tinguessin el mateix pes, la textura dominaria totalment la decisió matemàtica.

L'ús del PCA sobre el vector HOG també respon a la necessitat d'eliminar la redundància de les dades. En les imatges, els píxels i gradients veïns solen tenir informació molt repetida; el PCA transforma aquestes dades en noves variables totalment independents entre elles.

4 Preparació de l'Experimentació

Abans de procedir a l'entrenament dels models i a la validació amb imatges individuals, és necessari realitzar un pre-processament final de les dades per garantir la convergència dels algorismes i la reproductibilitat dels resultats.

4.1 Normalització de Dades

El vector de característiques construït conté variables amb magnituds molt dispars. Per exemple, la *Compacitat* pot tenir valors al voltant de 15-20, mentre que els descriptors HOG solen oscil·lar entre 0 i 1. Si s'introduïssin aquestes dades directament en un classificador basat en distàncies (com SVM o KNN), les variables amb magnituds més grans dominarien la decisió, eclipsant la informació de textura.

Per solucionar-ho, s'aplica una normalització **Z-Score** (standardització) a cada columna del vector de característiques:

$$x' = \frac{x - \mu}{\sigma} \quad (1)$$

On x és el valor original, μ és la mitjana de la característica en tot el dataset d'entrenament i σ és la desviació estàndard. Això centra les dades al voltant de 0 amb una desviació unitari.

4.2 Persistència dels Paràmetres per a Inferència

Un error comú en sistemes de visió per computador és normalitzar les imatges de test utilitzant les estadístiques de la pròpia imatge de test. Això és incorrecte, ja que el model espera que les dades estiguin en la mateixa escala relativa que les dades d'entrenament.

Per assegurar una inferència correcta en els tests individuals (fase de *Testing*), s'ha implementat un mecanisme de persistència que guarda els següents paràmetres generats durant la fase d'entrenament en un fitxer `Dades_Model.mat`:

- **Vector de Mitjanes (μ):** Per centrar les noves mostres.
- **Vector de Desviacions Estàndard (σ):** Per escalar les noves mostres.

- **Matriu de Coeficients PCA:** La matriu de transformació calculada sobre el HOG d'entrenament, necessària per projectar les característiques de les noves imatges al mateix espai latent de 150 dimensions.

D'aquesta manera, l'script de validació individual carrega aquesta "recepta" i aplica exactament les mateixes transformacions matemàtiques a les noves imatges, garantint la validesa de la predicció.

4.3 Metodologia global del sistema (pipeline complet)

Per facilitar la lectura i la reproductibilitat dels resultats, a continuació resumim el flux complet implementat als scripts de la pràctica:

1. **Segmentació (HSV + morfologia + filtres geomètrics).** La imatge RGB es transforma a HSV i es genera una màscara binària combinant tres llindars de color (vermell, blau i groc). Posteriorment s'apliquen operacions morfològiques (dilatació, ompliment de forats, erosió i obertura) i filtres geomètrics.
2. **Extracció del ROI i selecció del blob principal.** A partir de la màscara final es calcula la caixa contenidora (bounding box) i es retalla el ROI. Per estabilitzar el procés, es selecciona el component connectat (*blob*) de major àrea com a candidat principal.
3. **Extracció de característiques (forma + color + textura).** Del blob s'extreuen descriptors de forma (*compacitat*, *solidesa*, *extent* i *excentricitat*). Pel color, es calcula el percentatge de píxels del ROI que entren en rangs HSV per a vermell/blau/groc (només sobre píxels no negres). Pel contingut local, s'extreu HOG sobre el ROI redimensionat a 64×64 .
4. **Ponderació i reducció de dimensionalitat (PCA).** Les tres famílies de descriptors s'escalen amb pesos fixats experimentalment ($w_{shape} = 6$, $w_{color} = 2$, $w_{hog} = 0.3$). A continuació s'aplica PCA **només** a la part HOG i es projecten les dades a $k = 150$ components.
5. **Normalització i persistència.** El vector final (7 descriptors manuals + 150 components PCA) es normalitza amb Z-score. Es guarden els paràmetres necessaris per a inferència (μ , σ , `coeff_pca`, `mu_pca` i k) al fitxer `Dades_Model.mat`.
6. **Entrenament i validació (k-fold) + selecció de finalistes.** Amb la taula de característiques `TaulaFinal.mat` s'entrenen diversos classificadors i s'avaluen amb validació creuada estratificada ($k = 5$ quan és possible). Es comparen mètriques globals i per classe per escollir els models finalistes.
7. **Testing (imatge individual / dataset extern).** Finalment, es valida el sistema amb imatges individuals i amb un conjunt extern d'imatges (generalització), reutilitzant el mateix pipeline de segmentació i extracció de característiques, i aplicant els mateixos paràmetres guardats a `Dades_Model.mat`.

5 Experimentació i Resultats

En aquesta fase del projecte, hem sotmès el sistema a diverses proves per validar la robustesa dels descriptors dissenyats i seleccionar el millor classificador. L'objectiu principal és quantificar la precisió (*Accuracy*) del model i entendre quina informació visual (forma, textura o color) és més determinant per a la identificació correcta dels senyals de trànsit.

A continuació, detallem els experiments realitzats utilitzant l'eina *Classification Learner* i la validació amb imatges reals.

5.1 Experiment 1: Importància dels Descriptors (Ablation Study)

Aquest primer experiment té com a objectiu aïllar i avaluar l'impacte real del color en la classificació. Hem entrenat models en dos escenaris diferents per determinar si la identitat del senyal recau més en la seva estructura o en la seva cromàtica.

5.1.1 Configuració de l'Experiment

S'han comparat dos vectors de característiques utilitzant els mateixos conjunts d'entrenament i validació:

- **Escenari A (Estructural):** S'utilitzen 154 variables que inclouen només la Geometria i la Textura (HOG + PCA). S'elimina totalment la informació de color.
- **Escenari B (Complet):** S'utilitzen les 157 variables totals, afegint-hi els descriptors de color (percentatges HSV) a l'Escenari A.

5.1.2 Resultats i Discussió

Els resultats obtinguts amb els models de millor rendiment (SVM Quadràtic i Lineal) són els següents:

- **Sense Color (Escenari A):** Hem assolit una precisió del **96.9%**.
- **Amb Color (Escenari B):** Hem assolit una precisió del **97.1%**.

Aquestes dades demostren que la informació estructural (la silueta del senyal i el "dibuix intern capturat pel HOG) és el factor discriminador dominant. El sistema és capaç d'identificar els senyals gairebé perfectament en blanc i negre. La incorporació del color aporta una millora marginal del **+0.2%**, actuant com un mecanisme de refinament final per resoldre ambigüitats puntuals, però confirmant que el sistema és robust davant variacions d'il·luminació o desgast del color.

5.2 Experiment 2: Selecció del Classificador

En aquest experiment s'ha comparat el rendiment de diferents classificadors sobre el vector de característiques complet (forma + color + textura via HOG+PCA), amb

l'objectiu de triar el model final. La validació s'ha realitzat amb **k-fold cross validation** (**k=5**) i s'han analitzat tant mètriques globals (*accuracy*, *balanced accuracy* i *macro-F1*) com el rendiment per classe a través de la matriu de confusió i el *recall*.

Hem entrenat cinc models: SVM lineal (ECOC), SVM Gaussian, un ensemble de *bagging* d'arbres, regressió logística (ECOC) i LDA.

5.2.1 Resultats quantitatius (k-fold = 5)

La Taula 1 resumeix les mètriques globals i la velocitat de predicció. Per evitar que el desbalanceig domini la interpretació, donem especial importància a la *balanced accuracy* i al *macro-F1*.

Taula 1: Comparativa global dels classificadors (dataset intern, 2741 mostres).

Model	Accuracy	Bal. Acc.	Macro-F1	Velocitat (obs/s)
SVM lineal (ECOC)	0.9475	0.9334	0.9286	11013.8
SVM Gaussian	0.9752	0.9521	0.9605	4199.5
Ensemble Bagging	0.9668	0.9374	0.9494	2125.7
Logistic Regression	0.9646	0.9416	0.9499	19027.1
LDA	0.9628	0.9407	0.9496	21711.8

Com es veu, la **SVM Gaussià** és la millor en rendiment global (macro-F1 i *balanced accuracy*), mentre que **LDA** i **Logistic Regression** ofereixen una alternativa molt competitiva amb una velocitat de predicció molt superior.

5.2.2 Com funciona cada model i interpretació dels resultats

Tot i que tots els classificadors parteixen del mateix vector de característiques (forma + color + HOG+PCA), difereixen en el tipus de frontera de decisió que poden aprendre i en el seu cost computacional:

- **SVM lineal (ECOC)**: aprèn separacions lineals entre classes (hiperplans). És ràpida i estable, però perd rendiment quan la separació real és no lineal (canvis de perspectiva, mida o condicions d'il·luminació poden deformar l'espai de descripció).
- **SVM Gaussian**: utilitza un nucli gaussià (RBF) per modelar fronteres no lineals. Això li permet capturar millor relacions complexes entre descriptors, i és el motiu principal pel qual obté el millor *macro-F1* i *balanced accuracy* (Taula 1). Com a contrapartida, la inferència és més lenta.
- **Ensemble Bagging (arbres)**: crea molts arbres de decisió entrenats amb diferents mostres (bagging) i agrega per vot. És potent en patrons no lineals i interaccions entre variables, i sovint és robust a soroll. En el nostre cas queda entre els millors en mètrica global, però el cost de predicció és superior a models lineals.
- **Regressió logística (ECOC)**: model lineal probabilístic multi-classe via ECOC. És molt ràpid en inferència i generalitza bé quan les features ja separen

prou classes, cosa que explica el seu bon *macro-F1* amb una velocitat molt alta.

- **LDA**: model lineal basat en distribucions gaussianes per classe i projeccions discriminants. És extremadament ràpid i, tot i ser lineal, mostra un rendiment molt competitiu. A més, en aquest dataset obté el millor *recall* a **stop** (Taula 2), fet rellevant perquè **stop** és una classe crítica.

Per què escollim dos finalistes. Com a criteri de selecció final, busquem (i) màxim rendiment global (*macro-F1* i *balanced accuracy*) i (ii) robustesa davant variabilitat real. Amb aquest criteri, els dos models que destaquen com a finalistes són:

- **SVM Gaussian**: millor model global.
- **Ensemble Bagging**: rendiment global alt i capacitat no lineal, sovint robust amb soroll i variacions.

Tot i això, si la prioritat fos estrictament maximitzar la detecció de **stop** o si es necessités molta velocitat, **LDA** o **Logistic Regression** poden ser opcions molt atractives.

5.2.3 Anàlisi focalitzat en classes crítiques

La Taula 2 mostra el comportament per a dues classes especialment rellevants en el nostre cas: **stop** (classe històricament difícil) i **no_senyal** (classe afegida per entrenar la detecció de presència/absència de senyal).

Matrius de confusió (lectura ràpida). Per complementar aquestes mètriques, hem revisat les matrius de confusió (files = classe real, columnes = classe predita). Això permet identificar **quines confusions són recurrents** i, per tant, on cal actuar (més dades, millor segmentació o descriptors més específics). En els nostres resultats, la confusió més problemàtica és que part de **stop** es prediu com **no_senyal** (falsos negatius), especialment en imatges on el retall del ROI és incomplet o el fons/llum és complicat. Aquesta observació és coherent amb el fet que **stop** presenti el *recall* més baix a la Taula 2.

Taula 2: Mètriques per classe per a **stop** i **no_senyal**.

Model	Stop R	Stop P	Stop F1	No-senyal R	No-senyal P	No-senyal F1
SVM lineal	0.5545	0.5495	0.5520	0.7840	0.8660	0.8230
SVM Gaussià	0.5182	1.0000	0.6826	1.0000	0.8408	0.9135
Bagging	0.4636	1.0000	0.6335	0.9852	0.8263	0.8988
Logistic	0.5455	0.9091	0.6818	0.9408	0.8457	0.8908
LDA	0.6182	0.8000	0.6974	0.9497	0.8273	0.8843

Resultats globals. Els resultats mostren que la **SVM Gaussià (ECOC)** és el millor compromís global, aconseguint el valor més alt de *macro-F1* i una *balanced accuracy* superior a la resta. Models com LDA i la regressió logística queden molt a prop i presenten un comportament estable, mentre que la SVM lineal queda per

sota, indicant que les fronteres entre classes no són estrictament lineals en l'espai de característiques.

Anàlisi per classes (stop i no_senyal). La classe `stop` continua sent la més difícil: és la que presenta més confusions i un *recall* inferior a la resta de classes en la majoria de models. Tot i això, **hem afegit més imatges de la classe stop** i hem observat que **el rendiment d'aquesta classe ha augmentat respecte proves anteriors** (més encerts i menys falsos negatius en validació interna).

Per altra banda, la classe `no_senyal` mostra un comportament molt sòlid després de l'ampliació de dades: el sistema discrimina millor els casos on no hi ha cap senyal, reduint falsos positius en escenes reals.

5.2.4 Conclusions de l'Experiment 2

De la comparativa es desprenen diverses conclusions importants:

- **Millor model global:** la SVM Gaussià és la que obté millor rendiment agregat (Taula 1). Això suggereix que la relació entre les nostres features i les classes és **no lineal**, i que un model amb capacitat no lineal aprofita millor la informació de textura (HOG+PCA) i els descriptors de forma/color.
- **Trade-off precisió vs. velocitat:** models lineals com LDA i logística ECOC són extremadament ràpids (Taula 1) i queden molt a prop en macro-F1. Si el sistema hagués de funcionar en temps real amb recursos limitats, aquests models serien una alternativa molt raonable.
- **Classificació de stop:** continua sent la classe amb pitjor *recall* per a la majoria de models (Taula 2). Tanmateix, l'ampliació del dataset amb més imatges de `stop` ha reduït el nombre de falsos negatius i ha apujat el rendiment de la classe en validació interna. Entre els models provats, **LDA és el que assoleix el millor recall per a stop**.
- **Classe no_senyal:** l'ampliació d'aquesta classe ha estat clau per evitar que el sistema confongui fons complexos amb senyals. En els millors models, el *recall* de `no_senyal` és molt alt (Taula 2), tot i que es manté un trade-off amb la precisió (alguns falsos positius cap a `no_senyal`).

Finalment, justifiquem l'elecció de dos finalistes: **SVM Gaussià** (màxim rendiment global) i **Ensemble Bagging** (molt competitiu + robustesa no lineal). Aquesta elecció equilibra rendiment i robustesa; en una fase posterior, la decisió definitiva es pot reforçar amb proves en un conjunt extern (generalització) i amb criteris de temps d'inferència segons l'aplicació.

5.3 Model definitiu (proposta)


Per a la versió final del sistema proposem com a **model definitiu** la **SVM Gaussià en esquema ECOC (one-vs-all)**. La selecció es basa en maximitzar el rendiment **global** sobre el dataset intern, prioritzant *macro-F1* i *balanced accuracy* (mètriques més informatives en presència de desbalanceig). En els nostres experiments, aquest model ofereix el millor compromís de rendiment agregat.

Com a **alternativa finalista**, mantenim l'**Ensemble Bagging** perquè sovint és robust en escenaris no lineals i sorollosos. En conseqüència, la decisió es pot reforçar amb una validació externa: si a l'experiment de generalització (imatges externes) l'Ensemble degradés menys que la SVM Gaussià, seria una opció igualment defensible.

5.4 Experiment 3: Validació Qualitativa amb Imatges Externes


Per finalitzar l'avaluació, s'ha sotmès el sistema a una prova de generalització utilitzant imatges inèdites extretes d'Internet. Aquestes mostres serveixen per verificar la robustesa de la *Segmentació Universal* i comparar les prediccions dels models **SVM Gaussià** i **Ensemble Bagging**.

S'han seleccionat quatre tipus de senyals representatius de les categories geomètriques i cromàtiques principals.



Model	Classe Predita
SVM Gaussià	vianant
Ensemble	vianant

Figura 5: Resultat per al senyal de perill (Vianants). La segmentació aïlla el triangle groc eliminant el fons.




Model	Classe Predita
SVM Gaussià	d_prohibida
Ensemble	no_soroll

Figura 6: Prova amb senyal de prohibició. El filtre vermell pur ($R - G$) elimina els núvols del fons.



Model	Classe Predita
SVM Gaussià	stop
Ensemble	stop

Figura 7: Prova amb senyal STOP. Es comprova la interpretació de la forma octogonal.



Model	Classe Predita
SVM Gaussià	limit
Ensemble	d_obligatoria

Figura 8: Prova amb senyal d'obligació. S'avalua l'eliminació del cel mitjançant la substracció de canals.

5.4.1 Conclusions de l'Experiment 3

Els resultats qualitatius confirmen l'eficàcia de la *Segmentació Universal* en entorns no controlats, aconseguint aïllar correctament els senyals davant de fons complexos (cels ennuvolats, vegetació). Pel que fa a la classificació, s'observa una robustesa notable en formes geomètriques úniques; tant l'SVM Gaussià com l'Ensemble Bagging identifiquen correctament senyals triangulars (*vianant*) i octogonals (*stop*).

No obstant això, apareixen divergències en la morfologia circular. L'SVM Gaussià mostra una millor discriminació en senyals de prohibició vermells, però presenta errors creuats entre senyals blaus i límits de velocitat. Inversament, l'Ensemble Bagging classifica correctament el senyal d'obligació blau, però confon subclasses de prohibició específiques (e.g., *no_soroll* vs *d_prohibida*).

Finalment, cal destacar que, en avaluar el sistema amb imatges externes, la precisió global ha disminuït sensiblement respecte als resultats de la validació interna (on s'assolia un $\approx 96\%$). Aquest descens era esperable, ja que les mètriques sobre el dataset propi tendien a ser optimistes degut a l'homogeneïtat de les mostres; l'experiment extern reflecteix de manera més realista el repte de generalització i la dificultat inherent a la variabilitat de l'entorn real.

6 Conclusions i treball futur

Aquest treball presenta un sistema complet de detecció i classificació de senyals de trànsit basat en un **pipeline modular** (segmentació $\rightarrow$ ROI $\rightarrow$ descriptors $\rightarrow$ reducció + normalització $\rightarrow$ classificació). En conjunt, els resultats obtinguts en validació interna indiquen que, un cop el senyal queda **ben segmentat**, el problema de classificació es resol de manera molt fiable amb descriptors clàssics (forma + textura via HOG+PCA) i models supervisats.

6.1 Principals aportacions i decisions clau

- **Segmentació en HSV amb filtres geomètrics.** L'ús d'umbrals cromàtics (vermell/blau/groc) en HSV, reforçats amb morfologia i filtres d'àrea/aspect ratio/extent, permet eliminar gran part del fons en escenes reals. La lògica de *rescat* (escollir el blob més gran quan no hi ha cap candidat perfecte) millora el *recall* de detecció en casos adversos.
- **Vector de característiques híbrid.** La combinació de descriptors manuals de forma i percentatges de color amb HOG aporta informació complementària: la textura estructura la separació entre subclasses i el color actua com a refinament.
- **Reducció de dimensionalitat i persistència del pipeline.** Aplicar PCA només a la part HOG i guardar els paràmetres (PCA i Z-score) a `Dades_Model.mat` garanteix que l'entrenament i la inferència comparteixen exactament el mateix espai de representació.
- **Avaluació amb mètriques robustes al desbalanceig.** L'ús de *balanced accuracy* i *macro-F1*, acompanyat de matrius de confusió, permet entendre millor els errors que no pas una accuracy global.

6.2 Què hem après dels errors (limitacions)

Tot i el bon rendiment global, els errors no són aleatoris i apunten a limitacions concretes:

- **La segmentació és el coll d'ampolla.** Quan el ROI surt incomplet, massa petit o amb fons residual, la classificació tendeix a degradar-se de manera notable. Això explica que part de les errades es concentrin en escenes amb il·luminació difícil, oclusions o fons amb altres senyals.
- **Classes amb confusions estructurals.** Determinades subclasses comparteixen forma global (per exemple, senyals circulars), i aleshores el model depèn molt de la textura interna i de la qualitat del retall. Això pot generar confusions creuades entre prohibicions o entre senyals blaus i alguns límits de velocitat quan la segmentació no és neta.
- **Generalització: Molta diferencia entre dataset intern i extern.** És esperable que el rendiment caigui en imatges externes a causa de canvis de càmera, compressió, il·luminació, distància i perspectiva. Aquest efecte posa en valor la necessitat d'avaluar amb dades fora del conjunt d'entrenament.

6.3 Línies de millora (treball futur)

Per millorar el sistema sense canviar el plantejament global, proposem:

- **Millorar la segmentació universal** combinant HSV amb criteris addicionals (p. ex. detecció d'arestes i circularitat/triangularitat) i ajustant els llindars de manera adaptativa segons il·luminació.

- **Augment de dades i balanç de classes** (especialment per classes difícils), i incorporació de transformacions (rotació, escala, canvis de llum) per reduir el *domain shift* cap a imatges externes.
- **Avaluació externa quantitativa** (no només qualitativa), repetint el test amb un conjunt extern etiquetat i reportant les mateixes mètriques per comparar robustesa real dels finalistes.
- **Descriptors més invariants** (p. ex. LBP o HOG multi-escala) o, si fos permès, un enfocament CNN lleuger entrenat amb transfer learning.

6.4 Conclusió final

En conclusió, el sistema proposat demostra que una solució basada en tècniques clàssiques de visió per computador pot assolir un rendiment alt en un entorn controlat i raonablement robust en escenes reals, sempre que la segmentació proporcioni un ROI de qualitat. Amb la selecció del model definitiu (SVM Kernel Gaussia) i la persistència del pipeline de pre-processament, el projecte queda preparat per ser validat de manera exhaustiva en dades externes i evolucionar cap a una solució encara més generalitzable.